

基于 ARMA(p,q) 的 BTC/USDT 价格序列建模与检验

张津睿*

zhangjr1022@mails.jlu.edu.cn

20251101-2025 年 12 月 11 日

摘要

本文使用从 Binance 获取的 BTC/USDT 历史数据，对收益率序列进行平稳性检验与 ARMA(p,q) 建模。通过 ACF/PACF 初判与 AIC/BIC 模型选择，得到若干候选模型；利用 Ljung-Box 对残差进行白噪声检验，并给出短期滚动预测的性能评估。结果显示，纯 ARMA 模型对短期线性相关具有一定刻画能力，但在波动聚集与厚尾方面存在局限。本文讨论了局限的原因与可能的扩展方向（ARIMA/ARMA-GARCH 等）。

关键词： ARMA 模型；时间序列；加密资产；AIC/BIC；Ljung-Box

内容

1	引言	3
2	理论基础	3
2.1	平稳序列与 ARMA 模型	3
2.2	识别、估计与诊断	3
3	数据获取与预处理	3
3.1	数据来源与区间	3
3.2	获取方法（代码简述）	4
3.3	可视化展示	4
3.4	相关结构初判（ACF/PACF）	5
3.5	收益率描述性统计	5

*Alternative email: jerryzhang40@gmail.com

4	模型建立与估计	5
4.1	平稳性检验	5
4.2	阶数识别与估计方法	6
4.3	阶数选择 (AIC/BIC)	6
4.4	ARMA(0,2) 模型估计结果	7
4.5	收益率的相关结构与波动聚集	7
4.6	残差诊断与稳健性分析	7
4.7	滚动预测性能评估	8
5	结果与分析	9
6	结论与展望	9
A	附录：检验统计量	9

1 引言

近年来，比特币价格展现出显著的非线性与异方差特征，但其一阶线性自相关是否存在、强度几何如何，仍值得以经典时间序列框架进行核查。[1,2] 本文聚焦于回答：在适当预处理后， $ARMA(p,q)$ 是否能对 $BTC/USDT$ 收益率的短期动态提供有效刻画与预测？

2 理论基础

2.1 平稳序列与 ARMA 模型

令 $\{X_t\}$ 为（弱）平稳时间序列。 $AR(p)$ 、 $MA(q)$ 与 $ARMA(p,q)$ 分别定义为

$$AR(p): \quad X_t = c + \sum_{i=1}^p \phi_i X_{t-i} + \varepsilon_t, \quad (1)$$

$$MA(q): \quad X_t = \mu + \sum_{j=1}^q \theta_j \varepsilon_{t-j} + \varepsilon_t, \quad (2)$$

$$ARMA(p,q): \quad \Phi(L)X_t = c + \Theta(L)\varepsilon_t, \quad (3)$$

其中 L 为滞后算子、 $\Phi(L) = 1 - \sum_{i=1}^p \phi_i L^i$ 、 $\Theta(L) = 1 + \sum_{j=1}^q \theta_j L^j$ ， $\{\varepsilon_t\}$ 为白噪声。平稳性与可逆性分别要求 $\Phi(z) \neq 0$ 与 $\Theta(z) \neq 0$ 在单位圆内无根。

2.2 识别、估计与诊断

模型识别可基于 ACF/PACF 图与信息准则：

$$AIC = -2 \log L + 2k, \quad BIC = -2 \log L + k \log n,$$

其中 k 为参数个数， n 为样本量。残差独立性常用 Ljung-Box 统计量检验。

3 数据获取与预处理

3.1 数据来源与区间

本文使用 Binance 交易所的 $BTC/USDT$ K 线数据（频率：日；区间：2017-08-17-2025-11-07）。为规避价格层级非平稳性，后续以对数收益率 $r_t = \Delta \log P_t$ 为研究对象。


3.2 获取方法（代码简述）

Algorithm 1 数据读取与预处理（伪代码）


- 1: 读取 BTCUSDT_1d.csv（字段含 timestamp, close）
 - 2: 计算 $r_t = \log P_t - \log P_{t-1}$ 并删除缺失值
 - 3: 进行 ADF 平稳性检验；若不平稳则调整频率/区间或去极值
 - 4: 可选：对异常波动进行 Winsorize 处理
-

3.3 可视化展示


为了对 BTC/USDT 的基本统计特征形成直观认识，本节展示样本区间内的收盘价、对数收益率以及收益率平方的时间序列，如图 1 所示。



(a) BTC/USDT 收盘价时间序列



(b) 对数收益率 r_t 时间序列



(c) 收益率平方 r_t^2 时间序列

图 1: BTC/USDT 样本区间内的价格、收益率与收益率平方的时间序列

图 1a 展示了收盘价的整体走势，可以看到价格在样本区间内经历了多轮上涨与回调，呈现出显著的非平稳性特征。与此对应，图 1b 给出了对数收益率 r_t ，收益率序列大体围绕零均值随机波动，但在部分时段出现明显更大的振幅。图 1c 展示了收益率平方 r_t^2 ，极端值呈簇状分布，反映出典型的波动聚集（volatility clustering）现象，为后续可能的异方差模型（如 GARCH）提供了动机。

3.4 相关结构初判（ACF/PACF）

为考察对数收益率 $\{r_t\}$ 的线性相关结构，本文绘制其自相关函数（ACF）与偏自相关函数（PACF），如图 2 所示。




图 2: BTC/USDT 对数收益率的 ACF 与 PACF

从图中可以看到，除滞后 1 期外，ACF 与 PACF 在所有滞后阶数上的绝对值均落在 95% 置信区间内，说明收益率序列整体上近似白噪声，缺乏显著的线性自相关结构。滞后 1 的 PACF 出现轻微超出置信区间的现象，表明序列可能含有极弱的一阶自回归成分。因此，ARMA 模型的候选阶数通常可限制在低阶附近，例如 ARMA(1,0)、ARMA(0,1) 或 ARMA(1,1) 等。

3.5 收益率描述性统计

为进一步刻画 BTC/USDT 对数收益率 r_t 的分布特征，表 1 给出了样本区间内收益率的基本统计量。

表 1: BTC/USDT 对数收益率的描述性统计

统计量	数值
样本量 n	3004
均值 $\bar{r}$	0.00106
标准差 σ_r	0.03639
最小值	-0.50261
最大值	0.20295
偏度 (skewness)	—
峰度 (kurtosis)	—

4 模型建立与估计

4.1 平稳性检验

为检验对数收益率序列 $\{r_t\}$ 是否满足平稳性假设，本文对其进行 ADF 与 KPSS 两类互补的单位根检验。

首先，ADF 检验的统计量为 -38.03 ，对应的 $p\text{-value} < 10^{-6}$ ，显著拒绝单位根原假设；其 1% 显著性水平的临界值为 -3.43 ，因而收益率序列不存在单位根。

其次，KPSS 检验的统计量为 0.0566 ，远低于 10% 显著性水平的临界值 0.347 ，因此无法拒绝平稳原假设。

综上，两类检验结论一致，均支持对数收益率可以视为平稳序列，适合使用 $\text{ARMA}(p, q)$ 等基于平稳假设的模型进行建模。

4.2 阶数识别与估计方法

在前文已经确认对数收益率序列 $\{r_t\}$ 可以视为平稳的基础上，本节在 $\text{ARMA}(p, q)$ 框架下对其短期线性结构进行建模。

模型阶数的初步识别可以基于样本自相关函数（ACF）与偏自相关函数（PACF）图：若 ACF 呈拖尾而 PACF 在某一滞后阶数后截尾，则倾向于 AR 模型；反之则倾向于 MA 模型；若二者均拖尾，则考虑一般的 $\text{ARMA}(p, q)$ 形式。在实际操作中，本文在若干候选阶数组合上拟合 ARMA 模型，并计算其 Akaike 信息准则（AIC）与贝叶斯信息准则（BIC）：

$$\text{AIC} = -2 \log L + 2k, \quad \text{BIC} = -2 \log L + k \log n,$$

其中 L 为极大似然值， k 为参数个数， n 为样本量。通过比较不同候选模型的 AIC/BIC 值，选取信息准则最小的模型作为后续分析的基准模型。

在确定阶数 (p, q) 后，使用极大似然法估计模型参数，记拟合得到的模型为 $\text{ARMA}(\hat{p}, \hat{q})$ 。下一小节将对该模型的残差性质进行诊断检验。

4.3 阶数选择（AIC/BIC）

在确认收益率序列平稳后，本文在 $p, q \leq 3$ 的范围内对所有候选 $\text{ARMA}(p, q)$ 模型进行极大似然估计，并计算对应的 AIC 与 BIC。表 2 列出了其中 AIC 与 BIC 最小的若干模型。

表 2: 部分 ARMA 模型的信息准则比较

p	q	$\log L$	AIC	BIC
0	2	5698.2090	-11388.4181	-11364.3873
2	0	5698.1916	-11388.3832	-11364.3524
2	1	5698.3696	-11386.7391	-11356.7006
1	0	5695.3923	-11384.7847	-11366.7616
1	1	5697.1557	-11386.3113	-11362.2805

从表中可见，AIC 最小的模型为 $\text{ARMA}(0,2)$ ，而 BIC 最小的模型为 $\text{ARMA}(1,0)$ 。由于 AIC 倾向于选择预测性能更好的模型，本文采用 $\text{ARMA}(0,2)$ 作为基准模型；而

BIC 选出的 ARMA(1,0) 亦具有类似的拟合优度，说明 BTC/USDT 收益率序列的线性结构整体十分微弱。

4.4 ARMA(0,2) 模型估计结果

根据上一小节的信息准则比较，本文选取 AIC 最小的 ARMA(0,2) 作为 BTC/USDT 对数收益率序列的基准模型。对 $\{r_t\}$ 拟合 ARMA(0,2) 模型，得到的参数估计结果见表 3。

表 3: ARMA(0,2) 模型估计结果

参数	估计值	标准误	z 值	p 值
const	0.0011	0.0007	1.549	0.121
MA(1)	-0.0500	0.0118	-4.221	0.000
MA(2)	0.0454	0.0155	2.937	0.003
σ^2	0.0013	—	—	0.000

可以看到，常数项的估计值约为 0.0011，但在 10% 显著性水平下并不显著，说明 BTC/USDT 日度收益率的均值非常接近零。MA(1) 与 MA(2) 系数在 1% 显著性水平下均显著，表明收益率序列存在轻微的短期移动平均结构。整体来看，收益率的线性依赖关系较弱，这与前述 ACF/PACF 图的结论一致。

4.5 收益率的相关结构与波动聚集

对收益率序列的自相关性进行 Ljung–Box 检验，结果如下：

- 在 r_t 上：p 值在滞后 10、20、30 时分别为 0.0054, 0.0072, 0.0090，虽然部分滞后拒绝独立性，但整体相关性较弱。
- 在平方收益率 r_t^2 上：p 值均小于 10^{-12} ，在各滞后下均强烈拒绝独立性假设。

同时，ARCH LM 检验的 p-value 为 5.34×10^{-10} ，显著拒绝“无条件异方差”原假设。

上述证据表明：收益率序列表现为“均值无显著自相关、平方收益率存在强自相关”，即典型的波动聚集现象。这意味着单纯 ARMA 模型难以捕捉异方差结构，也为后续 GARCH 类建模提供了动机。

4.6 残差诊断与稳健性分析

在得到基准 ARMA(0,2) 模型后，对其残差序列 $\{\hat{\varepsilon}_t\}$ 进行诊断，以检验模型是否充分刻画了收益率的线性结构。

首先，对残差进行 Ljung–Box 检验。滞后 1 阶的统计量 $Q(1) \approx 0.00$ ，对应的 p 值约为 0.99，无法拒绝“残差为白噪声”的原假设，说明 ARMA(0,2) 已较好地消除了收益率中的线性自相关结构。

其次，利用 Jarque–Bera 统计量检验残差的正态性。结果得到 JB 值约为 30943.77， p 值显著小于 0.01，表明残差分布与正态分布存在显著差异，呈现出明显的尖峰厚尾特征。

再次，采用异方差检验（记统计量为 H ），结果为 $H \approx 0.28$ ，其 p 值同样远小于 0.01，显著拒绝“同方差”原假设。结合前文对平方收益率的 Ljung–Box 与 ARCH LM 检验结果可以看出，尽管 ARMA 模型成功捕捉了收益率的线性结构，但残差仍然存在显著的条件异方差性和厚尾，这正是金融时间序列中常见的波动聚集现象。

因此，ARMA(0,2) 更适合作为均值方程的描述，而要刻画波动的动态，还需要在此基础上进一步引入 GARCH 等波动模型，这也是未来工作的一个自然扩展方向。

4.7 滚动预测性能评估

为了检验 ARMA(0,2) 模型的短期预测能力，本文将样本划分为训练集（前 2804 条数据）与测试集（后 200 条数据），在训练集上估计模型参数，并对测试集进行一步滚动预测。预测均值与 95% 置信区间如图 3 所示。




图 3: ARMA(0,2) 模型在测试集上的一步预测结果

从图中可以看到，预测值紧密围绕零附近波动，而实际收益率在部分日期出现较大振幅，这导致模型的预测误差相对明显。为量化预测性能，本文计算了如下误差指标：

$$\text{RMSE} = 0.01823, \quad \text{MAE} = 0.01331, \quad \text{MAPE} = 120.09\%.$$

其中，MAPE 较高的原因在于收益率本身接近零，导致分母很小，从而放大了相对误差。总体来看，ARMA(0,2) 对收益率的方向或振幅均无法提供有效预测，其最佳预测几乎为常数 0。这与前述模型结构（弱线性相关、几乎白噪声）一致。

5 结果与分析

根据第四章的实证结果可以看出，BTC/USDT 日度收益率序列的可预测性极弱。ARMA(0,2) 虽然在 AIC 下最优，但预测均值几乎为零，且无法捕捉实际收益率的突发跳跃。预测误差 RMSE 与 MAE 均处于收益率波动的正常范围，MAPE 则由于收益率常接近零而偏大。该现象表明：收益率的均值过程近似随机游走，而波动过程却具有显著的条件异方差结构。ARMA 模型适合作为均值方程，但若要进一步提高预测效果，需要引入 GARCH 类模型以刻画波动动态。

所有数据可以使用github库中代码 [3]复现。

6 结论与展望

本文利用 Binance 提供的 BTC/USDT 日度数据，对对数收益率序列进行平稳性检验、相关结构分析以及 ARMA 模型的阶数选择与估计。实证结果表明：

- (1) 对数收益率序列在 ADF 与 KPSS 检验下均表现为平稳；
- (2) ACF/PACF 显示收益率的线性相关结构极弱；
- (3) AIC/BIC 选择得到的最优模型阶数非常低（如 ARMA(0,2) 或 ARMA(1,0)），且模型参数的经济意义有限；
- (4) 残差的 Ljung-Box 检验无法拒绝“白噪声”假设，说明 ARMA 已基本提取完可利用的线性结构；
- (5) 残差的厚尾性与异方差性显著（Jarque-Bera、ARCH LM 均显著），进一步说明收益率序列呈现典型的波动聚集特征。

综上，BTC/USDT 的日度收益率基本符合“弱效率市场假说”下的近似随机游走特征：均值过程难以通过线性模型进行预测，由 ARMA 模型给出的最佳预测几乎为常数。然而，收益率波动却具有显著的条件异方差性，表明其波动而非均值具有可建模性。

未来的研究方向包括：在 ARMA 均值方程的基础上引入 GARCH 类模型以刻画波动聚集；比较 ARMA、ARIMA 与随机游走模型的预测性能；进一步研究在不同采样频率（如 4h、1h）下的建模差异等。

A 附录：检验统计量

ADF 检验与Ljung-Box统计量的公式占位与推导提要。

参考文献 & 链接

- [1] George E. P. Box, Gwilym M. Jenkins, Gregory C. Reinsel, and Greta M. Ljung. *Time Series Analysis: Forecasting and Control*. Wiley, 5 edition, 2015. 经典时间序列教材, ARMA 模型定义与建模流程出处.
- [2] Peter J. Brockwell and Richard A. Davis. *Introduction to Time Series and Forecasting*. Springer, 3 edition, 2016. 教材级参考, 包含平稳性与信息准则理论.
- [3] Zhang Jinrui. test.py. https://github.com/jerzha40/2025_term_up_autumn_ps_probability_statistics_at_jlu/blob/prosperity-report/code/test.py. Accessed: 2025-11-08.